

商用人工智慧導論

Introduction of Artificial Intelligence for Business

第3週 監督式技術與軟體實務



學習目標

1. 瞭解人工智慧監督學習之基礎-線性迴歸之原理及理解程式碼。
2. 瞭解人工智慧監督學習-決策樹之原理及理解程式碼。
3. 瞭解人工智慧監督學習-隨機森林之原理及理解程式碼。
4. 瞭解人工智慧監督學習-支援向量機之原理及理解程式碼。




機器學習簡介

- 機器學習(Machine Learning)是一種數據分析技術，它教導計算機模仿人類從經驗中學習。
- 機器學習直接從數據「學習」資訊，而不依賴於預定的程式作為模型。
 - 小孩自然而然地「學」辨識貓。
- 傳統讓電腦辨識出貓的方法，需要將所有貓的特徵以窮舉法的方式。



機器學習的分類



監督式學習

- 在監督式學習中，提供演算法的訓練數據稱為標籤。
- 透過樣本的特徵劃分類別，以建立分類模型。
- 最後，輸入新的樣本即可知道相對應的類別。




用於分類的標記訓練集




◎ 圖 3-10 用於分類的標記訓練集

資料來源：人工智慧導論 (全華圖書)

用於監督學習的垃圾郵件分類



使用廣告預算來預估汽車的銷售量



機器學習演算法

迴歸(Regression)

- 迴歸是一種統計學上分析數據的方法，其目的是找出一個最能代表觀測資料關係的連續函數。



年資和薪資的資料集


◎ 表 3-1 年資和薪資的資料集

年資	薪資
1	30000
2	25000
3	35000
3.5	32000
4	35000
4.5	32000
6	35000
6	50000
7	40000

資料來源：人工智慧導論 (全華圖書)




年資和薪資的二維分佈圖




資料來源：人工智慧導論 (全華圖書)


迴歸預測



(a)迴歸直線方程式



(b)無數條的直線方程式




(c)誤差平方和為最小的直線

◎ 圖 3-23 迴歸預測




非線性函數




資料來源：人工智慧導論 (全華圖書)


預測模型



(a)十次方多項式的模型



(b)預測值在十次方多項式模型的趨勢



(c)預測值在二次方多項式模型的趨勢

◎ 圖 3-25 預測模型

資料來源：人工智慧導論 (全華圖書)



範例練習：線性迴歸

- 以下的範例是Boston的房價資料集。
- 共有14個特徵欄位，506筆資料。
 - CRIM：人均犯罪率。
 - ZN：住宅用地超過25,000平方英尺的比例。
 - INDUS：城鎮非零售商用土地的比例。
 - CHAS：是否鄰近查爾斯河(1：是、0：否)。
 - NOX：一氧化氮濃度。
 - RM：住宅的平均房間數。
 - AGE：1940年之前建造的自用房屋比例。
 - DIS：到波士頓五個中心區域的加權距離。
 - RAD：到達高速公路的方便性指標。
 - TAX：每萬元的全價值房屋稅。
 - PTRATIO：城鎮的師生比例。
 - B： $1000 \cdot (Bk - 0.63)^2$ ，(Bk：城鎮中黑人的比例)。
 - LSTAT：低收入人口的比例。
 - MEDV：自住房屋的平均房價(單位：千元美金)。



雲端Python編輯器

Google Colab



Colab 是什麼？


- Colab (全名為「Colaboratory」) 可讓你在瀏覽器中編寫及執行 Python 程式碼，並具有以下優點：
- 不必進行任何設定
- 免付費使用 GPU
- 輕鬆共用

以Google帳號登入以下Colab網站開始使用吧

<https://colab.research.google.com/>




使用迴歸預測Boston房價




資料來源：人工智慧導論 (全華圖書)

使用Kaggle選擇資料集

- Kaggle (<https://www.kaggle.com/>)
- 全世界最大的資料科學家競賽平台



決策樹(Decision Tree)



資料來源：人工智慧導論 (全華圖書)

炸雞的數據


◎ 表 3-2 炸雞的數據

編號	油溫	油炸時間	好不好吃
1	50	80	好
2	45	60	不好
3	19	100	不好
4	100	30	好
5	100	70	不好
6	70	30	?


資料來源：人工智慧導論 (全華圖書)



判斷炸雞是否好吃的決策樹



以油溫 and 油炸時間來分類




◎ 圖 3-29 以油溫和油炸時間來分類

範例練習：決策樹

- 以下的範例是鳶尾花的分類資料集。
- 共有4個欄位，150筆資料。
 - sepal length (cm)：花萼的長度。
 - sepal width (cm)：花萼的寬度。
 - petal length (cm)：花瓣的長度。
 - petal width (cm)：花瓣的寬度。




鳶尾花的花瓣長寬和花萼長寬



◎ 圖 3-30 鳶尾花的花瓣長寬和花萼長寬

鳶尾花資料集的決策樹




◎ 圖 3-31 鳶尾花資料集的決策樹

隨機森林(Random Forest)

- 一個隨機森林本質上是決策樹的集合，每棵樹略有不同。
- 每棵樹可能做相對好的預測，但也可能因部分數據而過度擬合。
- 如果我們建立很多樹，而這些樹都運作良好，以不同的方式過度擬合。
- 透過平均他們的結果來減少過度擬合的數量。
- 藉由保留樹的預測能力來減少過度擬合。



隨機森林的概念



資料來源：人工智慧導論 (全華圖書)

範例練習：隨機森林

- 接續上一節決策樹的範例，一樣使用鳶尾花的資料集。
- 此處的隨機森林使用RandomForestClassifier()建構隨機森林訓練模型，
`n_estimators = 10`代表使用10個決策樹形成隨機森林。




支持向量機(SVM)


- 支持向量機是一種監督式學習的分類器，它可以找到一個最佳超平面來對數據進行分類，並在兩類的數據之間找到分隔線。
- 支持向量機建立分隔線，一旦有一條有助於識別邊界，其他的分隔線的訓練數據即為多餘，提供來自給定數據集的最佳分類。
- 支持向量機的模型複雜性不受訓練數據中遇到的特徵數量的影響，亦非常適合處理學習任務，其中特徵數量相對於訓練實例的數量很大。



支持向量機-1




(a)紅色點和藍色點的數據集




(b)分割紅點和藍點的直線

圖 3-33 支持向量機

支持向量機-2



(c) 支撐向量點



(d) 兩個支持向量機的直線


圖 3-33 支持向量機 (續)

範例練習

- 此處資料集一樣使用鳶尾花的資料集，包含三種鳶尾花的花瓣長寬和花萼長寬資料，為了方便將預測結果視覺化，所以只選了Sepal length(花萼長)和Petal length(花瓣長)當成特徵，在平面空間上顯示。



使用SVM預測鳶尾花的品種



◎ 圖 3-34 使用 SVM 預測鳶尾花的品種