


商用人工智慧導論

Introduction of Artificial Intelligence for Business

第4週 非監督式技術與軟體實務



機器學習的分類



學習目標

1. 瞭解人工智慧非監督學習之基礎-K-平均分群之原理及理解程式碼。
2. 瞭解人工智慧非監督學習-DBSCAN之原理及理解程式碼。
3. 瞭解人工智慧非監督學習-階層式分群之原理及理解程式碼。
4. 瞭解人工智慧非監督學習-關聯規則之原理及理解程式碼。



K-平均分群 (K-means)

- 分類為事先定義好分類的標籤，依據標籤將資料分類
- 分群是直接用資料的特徵將資料分成不同的群，同一群的資料性質相似，不同群的資料性質差異大



K-means演算法

1. 隨機選取資料集K個點當作群中心。
2. 資料集中的每個點計算與K個群中心的距離，選擇距離最近的群中心加入該群。
3. 每一群重新計算群中心，如果所有群中心都不再變化，則分群結束。
4. 繼續執行步驟(2)至(3)。



K-means資料集

◎ 表 3-7

(a)資料集各點座標

點	座標
A	(0, 0)
B	(1, 1)
C	(2, 1)
D	(1, 3)
E	(2, 4)
F	(3, 3)

(b)各點到群中心 B 和 C 的距離

	B	C
A	1.4	2.2
D	2	2.2
E	3.2	3
F	2.8	2.2

(c)各點到群中心(0.7, 1.3)和(2.3, 2.7)的距離


	(0.7, 1.3)	(2.3, 2.7)
A	1.5	3.5
B	0.4	2.1
C	1.3	1.7
D	1.7	1.3
E	3	1.3
F	2.9	0.8

(d)各點到群中心(1, 0.7)和(2, 3.3)的距離


	(1, 0.7)	(2, 3.3)
A	1.2	3.9
B	0.3	0.5
C	1	2.3
D	2.3	1
E	3.6	0.7
F	3	1




K-平均分群法




(a) K-平均分群法的範例



(b) 第一回合分群結果



(c) 第二回合分群結果



(d) 最後分群結果

◎ 圖 3-42 K-平均分群法




範例練習

- 以下的範例是使用`make_blobs()`產生300個亂數點的資料集，分成三群，每群的標準差為1。




使用K-means分群

(cluster_std=1)




使用K-means分群

(cluster_std=2)




使用K-means分群

(cluster_std=3)




How to find the K in K-means

- 肘部法則 (Elbow Method) :
 - 肘部法則涉及計算不同 k 值下的**集群內**誤差平方和 (SSE , 也稱為失真程度) 。
 - 隨著 k 值增加 , SSE 通常會減小 , 因為聚類更細。我們尋找一個 “肘點” , 即**增加 k 值對減小 SSE 的貢獻變得不再顯著**的點。這個點可能是最佳的 k 值。



How to find the K in K-means

- 輪廓分析 (Silhouette Analysis) :
 - 輪廓分析使用輪廓係數來衡量每個數據點與所屬簇內其他點之間的相似性以及與最近簇之間的相似性。
 - 輪廓係數的值介於 -1 和 1 之間。輪廓分析的目標是選擇具有最大平均輪廓係數值的 k 值。



How to find the K in K-means

- 輪廓係數計算步驟

1. 對於數據集中的每個數據點 i ，計算 $a(i)$ ，即 i 與其所屬簇內其他點的平均距離。
 2. 對於每個數據點 i ，計算 $b(i)$ ，即 i 與最近的簇（即不是其所屬簇的簇）中所有點的平均距離。
 3. 對於每個數據點 i ，計算輪廓係數 $s(i)$ ，其計算公式為：
$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$
- 在計算所有數據點的輪廓係數後，通常會計算平均輪廓係數，以評估整個聚類結果。在實踐中，可以通過改變 k （簇的數量）並繪製 k 值與平均輪廓係數之間的關係來尋找最佳 k 值。



How to find the K in K-means

- 輪廓係數計算步驟

- 範例數據：

編號	X1	X2
1	1	1
2	1	2
3	2	1
4	9	9
5	9	10
6	10	9

- 兩個簇：編號 1, 2, 3 的點屬於簇A，編號 4, 5, 6 的點屬於簇B。



How to find the K in K-means

- 輪廓係數計算步驟

- 範例數據：

1. 計算 $a(i)$ ：對於每個數據點 i ，計算其與其所屬簇內其他點的平均距離。

- $a(1) = (\text{距離}(1, 2) + \text{距離}(1, 3)) / 2$
- $a(2) = (\text{距離}(2, 1) + \text{距離}(2, 3)) / 2$
- 以此類推...

2. 計算 $b(i)$ ：對於每個數據點 i ，計算其與最近的簇（即不是其所屬簇的簇）中所有點的平均距離。

- $b(1) = (\text{距離}(1, 4) + \text{距離}(1, 5) + \text{距離}(1, 6)) / 3$
- $b(2) = (\text{距離}(2, 4) + \text{距離}(2, 5) + \text{距離}(2, 6)) / 3$
- 以此類推...

3. 計算 $s(i)$ ：對於每個數據點 i ，計算輪廓係數。

- $s(i) = (b(i) - a(i)) / \max(a(i), b(i))$
- 計算出所有數據點的輪廓係數後，可以計算平均輪廓係數以評估聚類效果。

編號	X1	X2
1	1	1
2	1	2
3	2	1
4	9	9
5	9	10
6	10	9



K-means python程式實作

- 紅酒分組，相關特徵如下：
 - Alcohol: 酒精
 - Malic Acid: 蘋果酸
 - Ash: 灰分
 - Ash Alcalinity: 灰分鹼度
 - Magnesium: 鎂
 - Total Phenols: 總酚
 - Flavanoids: 黃酮類
 - Nonflavanoid Phenols: 非黃酮類酚
 - Proanthocyanins: 花青素
 - Color Intensity: 色澤濃度
 - Hue: 色調
 - OD280: OD280吸光度（一種衡量葡萄酒中酚類化合物的方法）
 - Proline: 脯氨酸




DBSCAN


- DBSCAN是一種基於密度的分群演算法
- 將相距較近的點聚成一群，然後不斷找鄰居點並加入此群中，直到群無法再擴大，然後再處理其他未拜訪的點
- DBSCAN的特色是不需要預先設定群的數量，可以找出任何形狀的群，並且一些與群比較遠的點當做離群點去掉



使用K-平均分群法



DBSCAN分群法-1



DBSCAN分群法-2




圖 3-47 DBSCAN 分群法(續)

DBSCAN分群法-3





圖 3-47 DBSCAN 分群法(續)

DBSCAN分群法-4



(g)半徑距離 ϵ 的大小影響分群的結果

◎ 圖 3-47 DBSCAN 分群法(續)

DBSCAN 演算步驟

1. 選擇參數:

- `eps`: 鄰域的大小，即點之間的最大距離，可以被視為鄰居。
- `min_samples`: 形成一個密集區域所需的最小點數。

2. 標記核心點、邊界點和噪聲:

- 核心點: 在`eps`距離內至少有`min_samples`個鄰居的點。
- 邊界點: 在`eps`距離內少於`min_samples`但至少有一個核心點的點。
- 噪聲: 不是核心點也不是邊界點的點。

3. 形成聚類:

- 從任一未訪問的核心點開始，搜尋並擴展聚類，將所有可達的核心點和邊界點納入同一聚類。
- 重複此過程直到所有點都被訪問。




範例練習

- 此處的資料集產生是以原點為同心圓，在圓周上使用自訂的函數 `CreatePointsInCircle(r, n=100)` 產生資料集，其中 r 代表同心圓的半徑， n 代表產生資料集的數量。
- 首先算出在半徑 r 的圓周上，平均分成 n 個點，第 i 點的座標為 $(\cos(2\pi/n*i)*r, \sin(2\pi/n*i)*r)$ ，為了產生亂數的效果，所以每個點 x 和 y 座標分別加上 $(-30, 30)$ 間的亂數




使用DBSCAN

分群資料集($\text{eps}=30$, $\text{min_samples}=6$)



使用DBSCAN

分群資料集($\text{eps}=20$, $\text{min_samples}=6$)



階層式分群

- 階層式分群法是具有階層結構的集群
- 可以透過將較小的集群迭代地合併到較大的集群中
- 或者將較大的集群劃分為較小的集群



聚合式階層分群法的步驟

1. 將每一個資料當作一個群。
2. 找到一組最近的集群並將它們合併到一個集群中。
3. 重複步驟2，直到形成的集群數等於事先定義的值。



任兩群間的距離

◎ 表 3-8 (a) A、B、C、D、E 和 F 任兩群間的距離 (b) A、D、E、F 和 P 任兩群間的距離 (c) A、F、P 和 Q 任兩群間的距離 (d) A、P 和 R 任兩群間的距離

(a)

	A	B	C	D	E	F
A	0	1.4	2.2	3.2	4.5	4.2
B		0	1	2	3.2	2.8
C			0	2.2	3	2.2
D				0	1.4	2
E					0	1.4
F						0

(b)

	A	D	E	F	P
A	0	3.2	4.5	4.2	1.8
D		0	1.4	2	2
E			0	1.4	3
F				0	2.5
P					0

(c)


	A	F	P	Q
A	0	4.2	1.8	3.8
F		0	2.5	1.6
P			0	2.5
Q				0

(d)

	A	P	R
A	0	1.8	3.9
P		0	2.3
Q			0




階層式分群法-1




◎ 圖 3-50 階層式分群法

階層式分群法-2




◎ 圖 3-50 階層式分群法 (續)

階層式分群法-3



聚合式階層分群法的樹狀圖



範例練習

- 以下以6個點 $X = [[0,0], [1,1], [2,1], [1,3], [2,4], [3,3]]$ 當作階層式分群的資料集。



範例解答

- 初始化：將每個數據點視為一個簇。有6個簇：
 - C1: [[0,0]]
 - C2: [[1,1]]
 - C3: [[2,1]]
 - C4: [[1,3]]
 - C5: [[2,4]]
 - C6: [[3,3]]
-
- 計算距離矩陣：使用歐氏距離和單連接方式計算距離矩陣。例如， $d(C1, C2) = \sqrt{(1-0)^2 + (1-0)^2} = \sqrt{2}$ 。



範例解答

- 合併最近的簇：找到距離最近的兩個簇。在這種情況下，C2 和 C3 的距離最小，為1。將它們合併成一個新的簇。現在有5個簇：
 - C1: $[[0,0]]$
 - C2: $[[1,1], [2,1]]$
 - C4: $[[1,3]]$
 - C5: $[[2,4]]$
 - C6: $[[3,3]]$
-
- 更新距離矩陣：重新計算新簇與其他簇之間的距離，並更新距離矩陣。




範例解答

- 重複步驟 3 和 4，直到所有數據點都合併成一個簇。以下是合併過程：
- 合併 C4 和 C6，距離為2。
- 合併 C1 和 C2，距離為 $\sqrt{2}$ 。
- 合併 C2 和 C4，距離為2。
- 最後，合併剩下的兩個簇 C2 和 C5，距離為3。
- 提取分群結果：觀察樹狀圖可以幫助我們選擇合適的截斷層次。在這個例子中，根據需要選擇截斷層次，可以得到2個、3個或更多的簇。例如，如果選擇距離閾值為2.5，則可以得到3個簇： $[[0,0], [1,1], [2,1]]$ 、 $[[1,3], [3,3]]$ 和 $[[2,4]]$ 。



使用階層式分群資料集



關聯規則 (Association Rule)

- 關聯規則學習主要是依據資料集性找出**頻繁**出現的**項目組合**。
- 因為常用在商品資料上，所以也被稱為購物籃分析(Basket Data Analysis)。
- 關聯規則的目標是找出共同出現的組合，稱為頻繁樣式，組合之間的關係稱為關聯。



信賴度、支持度

- 信賴度(Confidence)是指兩個項目集之間的條件機率，也就是在A出現的情況下，B出現的機率。
- 支持度(Support)是指每筆交易中同時包含A與B的交集機率。



舉例

- 假設有以下購物籃數據：

- {牛奶, 麵包, 果醬}
- {牛奶, 麵包}
- {果醬, 蘋果}
- {牛奶, 麵包, 蘋果}
- {麵包, 果醬}

購物籃交易	牛奶	麵包	果醬	蘋果
1	1	1	1	0
2	1	1	0	0
3	0	0	1	1
4	1	1	0	1
5	0	1	1	0



舉例：支持度

購物籃交易	牛奶	麵包	果醬	蘋果
1	1	1	1	0
2	1	1	0	0
3	0	0	1	1
4	1	1	0	1
5	0	1	1	0

- 單一產品的支持度

- 支持度(牛奶)：5筆購物籃交易中，牛奶出現3筆，因此支持度為 $3/5 = 0.6$ 。
- 支持度(麵包)：麵包出現4筆，支持度為 $4/5 = 0.8$ 。
- 支持度(果醬)：果醬出現3筆，支持度為 $3/5 = 0.6$ 。
- 支持度(蘋果)：蘋果出現2筆，支持度為 $2/5 = 0.4$ 。



舉例：支持度

購物籃交易	牛奶	麵包	果醬	蘋果
1	1	1	1	0
2	1	1	0	0
3	0	0	1	1
4	1	1	0	1
5	0	1	1	0

- 兩個產品的項目集支持度

- {牛奶, 麵包}：5個購物籃中，{牛奶, 麵包}出現3筆（購物籃1, 2, 4），支持度為 $3/5 = 0.6$ 。
- {牛奶, 果醬}：{牛奶, 果醬}只出現在1筆（購物籃1），支持度為 $1/5 = 0.2$ 。
- {牛奶, 蘋果}：{牛奶, 蘋果}只出現在1筆（購物籃4），支持度為 $1/5 = 0.2$ 。
- {麵包, 果醬}：{麵包, 果醬}出現在2筆（購物籃1, 5），支持度為 $2/5 = 0.4$ 。
- {麵包, 蘋果}：{麵包, 蘋果}只出現在1筆（購物籃4），支持度為 $1/5 = 0.2$ 。
- {果醬, 蘋果}：{果醬, 蘋果}只出現在1筆（購物籃3），支持度為 $1/5 = 0.2$ 。

計算出所有可能的項目集支持度後，可以根據**最小支持度**閾值過濾掉低支持度的項目集



舉例：信賴度

- 給定一個關聯規則 $A \rightarrow B$ ，信賴度是指在包含 A 的所有交易中， B 也同時出現的概率。換句話說，信賴度反映了在 A 發生的情況下， B 發生的概率有多高。
- 信賴度的計算公式如下：
- 信賴度 (Confidence) = $P(B | A) = \text{支持度}(A \text{ and } B) / \text{支持度}(A)$
- 其中， $P(B | A)$ 是在 A 出現的情況下 B 出現的概率；支持度 ($A \text{ and } B$) 是 A 和 B 同時出現的概率；支持度 (A) 是 A 出現的概率。



舉例：信賴度

購物籃交易	牛奶	麵包	果醬	蘋果
1	1	1	1	0
2	1	1	0	0
3	0	0	1	1
4	1	1	0	1
5	0	1	1	0

- 計算關聯規則 “麵包 -> 果醬” 的信賴度：
- 第一步驟：
 - 計算支持度 (麵包 and 果醬)，即麵包和果醬同時出現的次數，等於 2 (在購物籃 1、5)。
 - 計算支持度 (麵包)，即麵包出現的次數，等於 4 (在購物籃 1、2、4、5)。
- 第二步驟：
 - 根據計算公式，信賴度 (麵包 -> 果醬) = 支持度 (麵包 and 果醬) / 支持度 (麵包) = $2/4 = 0.5$ ，表示在包含麵包的購物籃中，果醬也出現的概率是 50%。

$$\text{信賴度 (Confidence)} = P(B | A) = \text{支持度 (A and B)} / \text{支持度 (A)}$$



Apriori演算法

- 用來解決運算量過大的方法。
- Apriori 所採用的特性是：「若一項目集是頻繁的，則它的所有非空子集合也必定是頻繁的。」。
- 從數量低的集合開始做起，當發現某個集合不是頻繁的，則他的母集合也不需要考慮，這樣可以大幅縮減計算的複雜度。



顧客消費紀錄

◎ 表 3-9 顧客消費紀錄

購買編號	購買產品
1	蘋果(A)、啤酒(B)、餅乾(C)、尿布(D)
2	蘋果(A)、尿布(D)
3	蘋果(A)、啤酒(B)、尿布(D)
4	尿布(D)



產品購買的次數和支持度

◎ 表 3-10 (a)單一產品購買的次數和支持度 (b)兩種產品一起購買的次數和支持度 (c)三種產品一起購買的次數和支持度

(a)

產品	購買次數	支持度
A	3	75%
B	2	50%
C	1	25%
D	4	100%

(b)


產品	購買次數	支持度
AB	2	50%
AD	3	75%
BD	2	50%

(c)


產品	購買次數	支持度
ABD	2	50%



全部產品的組合和Apriori



◎ 圖 3-53 全部產品的組合



◎ 圖 3-54 Apriori 的方法

項目集關聯性的信賴度

◎ 表 3-11 項目集關聯性的信賴度

項目集	關聯	信賴度
AB	$A \Rightarrow B$	67%
	$B \Rightarrow A$	100%
AD	$A \Rightarrow D$	100%
	$D \Rightarrow A$	75%
BD	$B \Rightarrow D$	100%
	$D \Rightarrow B$	100%
ABD	$A \Rightarrow BD$	67%
	$B \Rightarrow AD$	100%
	$D \Rightarrow AB$	50%
	$AB \Rightarrow D$	100%
	$AD \Rightarrow B$	67%
	$BD \Rightarrow A$	100%



在Kaggle找資料吧


- Kaggle是全世界最大的資料科學家數據建模和數據分析競賽最大的平台。企業和研究者可在其上發布數據，統計學者和數據挖掘專家可在其上進行競賽以產生最好的模型。這一眾包模式依賴於這一事實，即有眾多策略可以用於解決幾乎所有預測建模的問題，而研究者不可能在一開始就了解什麼方法對於特定問題是最為有效的。

<https://www.kaggle.com>



在Kaggle找資料吧

- 在搜尋欄位上打上關鍵字，如clustering, classification...etc



The screenshot displays the Kaggle website interface. On the left is a sidebar with navigation links: Create, Home, Competitions, Datasets (highlighted), Models, Code, Discussions, Learn, and More. Below these are 'Your Work' and 'RECENTLY VIEWED' items, including 'Wine Dataset for Clust...', 'Shop Customer Data', 'Mobile Price Classifica...', 'Predict Diabetes', and 'COVID-19 Dataset'. The main content area features a search bar at the top, followed by the 'Datasets' section with a description: 'Explore, analyze, and share quality data. Learn more about data types, creating, and collaborating.' Below this are buttons for '+ New Dataset' and 'Your Work'. A secondary search bar for 'Search datasets' is present, along with filter tags: All datasets, Computer Science, Education, Classification, Computer Vision, NLP, Data Visualization, and Pre-Trained Model. The 'Trending Datasets' section shows four featured datasets: 'Top 100 KDrama 2023' by Gianina-Maria Petrascu, 'Box-Office Secrets with TMDB Trends' by Shiv_D24Coder, 'Real Interest Rates' by Uirik Thyge Pedersen, and 'House price index (2015 = 100) - annual data in EU' by Sándor Burian. Each dataset card includes a thumbnail image, title, author, update time, usability score, file size, and file format.

Kaggle

+ Create

Home

Competitions

Datasets

Models

Code

Discussions

Learn

More

Your Work

RECENTLY VIEWED

- Wine Dataset for Clust...
- Shop Customer Data
- Mobile Price Classifica...
- Predict Diabetes
- COVID-19 Dataset

Search

Datasets

Explore, analyze, and share quality data. [Learn more](#) about data types, creating, and collaborating.

+ New Dataset Your Work

Search datasets

Filters

All datasets Computer Science Education Classification Computer Vision NLP Data Visualization Pre-Trained Model

Trending Datasets

See All



Top 100 KDrama 2023

Gianina-Maria Petrascu · Updated 13 hou...

Usability **9.4** · 34 kB

1 File (CSV)



Box-Office Secrets with TMDB Trends

Shiv_D24Coder · Updated 18 hours ago

Usability **9.4** · 88 kB

1 File (CSV)



Real Interest Rates

Uirik Thyge Pedersen · Updated 19 days ...

Usability **10.0** · 57 kB

1 File (CSV)



House price index (2015 = 100) - annual data in EU

Sándor Burian · Updated 17 days ago

Usability **10.0** · 3 kB

1 File (CSV)



利用chatGPT幫你寫程式吧 (GPT4. the latest ver.)

- 只要會問問題，並且問對問題！

